

7 КРАСНЫХ ЛИНИЙ

TECHNICAL DEEP DIVE

Архитектура и Безопасность

Изоляция коммерческой тайны (Zero Trust), локальные LLM с открытыми весами и детерминированная расчётная модель.



7 КРАСНЫХ ЛИНИЙ

Принцип Zero Trust

Физическая и логическая изоляция данных Заказчика.

Изоляция коммерческой тайны

Обработывает документы, опорную базу и результаты расчётов исключительно локальными моделями с открытыми весами (размещёнными на мощностях Заказчика).

Документы Заказчика в исходном виде **никогда не передаются за пределы контура**. Нет API-вызовов к публичным облакам.



On-Premise

Система разворачивается на выделенных серверах (Bare Metal или изолированных VM) внутри вашего дата-центра.

7 КРАСНЫХ ЛИНИЙ

Архитектура Двух Контуров

Разделение потоков для внешних и внутренних задач.

ВНУТРЕННИЙ КОНТУР (ЗАКРЫТЫЙ)

Обработка СМР и Смет

Сметы, финмодели, историческая БД. Локальные LLM-агенты (ГИП, Сметчик) работают здесь.

ВНЕШНИЙ КОНТУР (АНОНИМНЫЙ)

Поиск и Тендеры

Применяется для задач, требующих обращения к внешним источникам (поиск подрядчиков).

Протокол Маскирования

Передача данных во внешний контур выполняется по жёсткому регламенту с обязательной анонимизацией (удаление ИНН, адресов объектов, точных сумм и коммерческих условий) исходных данных до запуска процесса.

7 КРАСНЫХ ЛИНИЙ

Выбор LLM и Моделей

Свобода от вендор-лока.

Опенсорсные веса

Мы не привязываемся к одной нейросети. Конкретный состав семейства LLM фиксируется протоколом на Этапе 1 по результатам тестирования на реальных документах АПРИ.

Смена и обновление модели выполняются простым **изменением конфигурации** (YAML/JSON) без переработки прикладного кода Системы (FastAPI).

Zero Token Cost

Плата за обращения к локальной модели не взимается и не зависит от интенсивности использования.

7 КРАСНЫХ ЛИНИЙ

Математика: Decimal Модуль

Полный отказ от галлюцинаций LLM при работе с цифрами.

Детерминированные вычисления

Модели используются только для семантического анализа текстов и поиска аномалий. Все числовые показатели (сумма по разделам, БДДС, налоги, маржа) рассчитывает **строгий расчётный модуль на Python (библиотека Decimal)**.

ТОЧНОСТЬ

Сходимость

Сумма разделов обязана сходиться с итогом источника до рубля. Никаких округлений чисел с плавающей точкой (float).

7 КРАСНЫХ ЛИНИЙ

Интеграция: API и StorHaus

Слой получения данных.

Интерфейсы

Наполнение данными решается посредством интеграции со StorHaus или через структурированные файлы по API. Тестовый набор загружается автоматически.

7 КРАСНЫХ ЛИНИЙ

ETL пайплайн

Очистка и валидация.

Pydantic Схемы

Все извлечённые LLM данные проходят жёсткую валидацию типов через Pydantic. Некорректные JSON отбрасываются.

7 КРАСНЫХ ЛИНИЙ

Требования к инфраструктуре

Hardware sizing.

GPU VRAM requirements

Для работы моделей класса 7B/14B требуется от 24GB до 80GB VRAM (уровень NVIDIA A10G / A100). Итоговая конфигурация уточняется на Этапе 1.

7 КРАСНЫХ ЛИНИЙ

Развёртывание: Этап 1

135 дней до ОПЭ.

Инфраструктура и Тесты

Выбор семейства моделей, замер нагрузки на документах Заказчика. Развёртывание в контуре.

7 КРАСНЫХ ЛИНИЙ

Развёртывание: Этапы 2-4

Настройка и запуск.

Опорная база и Агенты

Формирование базы из 250+ объектов. Настройка агентов. Приёмка на двух реальных объектах (>80% по чек-листу).

7 КРАСНЫХ ЛИНИЙ

Ограничения по интеграции 1С

Границы проекта.

1С:ERP

Глубокая двусторонняя интеграция с 1С (коннекторы, обратная запись) не входит в рамки текущего проекта.

7 КРАСНЫХ ЛИНИЙ

Архитектура Агентов

Микросервисы.

Оркестрация очередей

Асинхронная обработка файлов через RabbitMQ / Redis. Параллельный запуск агентов ГИП, Сметчик, Юрист.

7 КРАСНЫХ ЛИНИЙ

База Данных (StorHaus)

Схема хранения.

Реляционная + Векторная СУБД

Использование PostgreSQL для финансовых данных и векторной БД (Qdrant/Milvus) для семантического поиска по историческим сметам.

7 КРАСНЫХ ЛИНИЙ

Обучение модели (RAG)

Дообучение без изменения весов.

Retrieval-Augmented Generation

Модель дообогатается историческими данными АПРИ (закрытые объекты). Данные остаются в контуре и подаются в контекст запроса, а не в веса модели.

7 КРАСНЫХ ЛИНИЙ

Мониторинг (Observability)

Контроль работы агентов.

Prometheus / Grafana

Сбор метрик: время ответа (SLA < 15 мин), количество токенов, загрузка GPU, количество ошибок валидации.

7 КРАСНЫХ ЛИНИЙ

Техническая гарантия

SLA на код.

12 месяцев поддержки

Устранение багов, восстановление работы при сбоях.

7 КРАСНЫХ ЛИНИЙ

Ролевая модель доступа (RBAC)

Управление правами.

Изоляция пользователей

Инженер ПТО видит только акты КС-2. Финдиректор видит сводную маржу. Интеграция с корпоративным SSO (LDAP / Active Directory).

7 КРАСНЫХ ЛИНИЙ

Производительность (SLA)

Метрики скорости.

Время расчёта

Короткий вывод — до 15 минут. Полный расчёт (15000 позиций) — до 1 часа. Углублённый разбор — до 5 часов. Зависит от выделенных GPU Заказчика.

7 КРАСНЫХ ЛИНИЙ

Инструменты OCR

Чтение PDF и сканов.

Computer Vision

Агент-Администратор использует модели LayoutLM для извлечения таблиц из скан-копий с печатями.

7 КРАСНЫХ ЛИНИЙ

Масштабируемость

Кластеризация.

Горизонтальное масштабирование

Отсутствие ограничений на число проверок, объектов и пользователей. Масштабируется добавлением workers в Kubernetes.

7 КРАСНЫХ ЛИНИЙ

Права на код

Интеллектуальная собственность.

Владение данными

Базовая платформа — 7КЛ. Данные, отчёты и опорная база — принадлежат Заказчику.

7 КРАСНЫХ ЛИНИЙ

Резервное копирование

Отказоустойчивость.

Backups

Настраивается силами IT-департамента Заказчика на основе инфраструктурных требований 7КЛ.

7 КРАСНЫХ ЛИНИЙ

Обновление моделей

CI/CD пайплайн.

Бесшовный деплой

Замена весов модели происходит без остановки основного контура через blue/green deployment.

7 КРАСНЫХ ЛИНИЙ

Внешние API (Опционально)

Что во внешнем контуре.

Спарк, Контур.Фокус

Интеграция с сервисами проверки контрагентов для Агента 4 (Юрист/Поиск).

7 КРАСНЫХ ЛИНИЙ

Архитектура (Summary)

Итог.

Надёжность и Безопасность

Система спроектирована для работы в Enterprise-среде с нулевым доверием к внешним сетям.