

Инженерная Безупречность

Zero Trust изоляция, детерминированная математика Decimal и локальные открытые веса (LLM).



Принцип Zero Trust

Абсолютная изоляция вашей коммерческой тайны. Физическое отсутствие связи с публичными облаками.

Изоляция данных

Система разворачивается на выделенных серверах (Bare Metal или изолированных VM) внутри контура Заказчика.

- Сметы, финмодели, историческая БД обрабатываются исключительно локальными моделями.
- Никаких API вызовов к OpenAI, Yandex или Sber.

Два Контура

Внутренний контур (Закрытый) используется для смет и договоров. Внешний контур (Анонимный) применяется для поиска подрядчиков. Передача данных во внешний контур выполняется после алгоритмического удаления ИНН, адресов и сумм.

Стоимость генерации токенов в контуре (Zero Token Cost):

\$0.00

Плата за обращения к локальной LLM-модели не взимается и не зависит от интенсивности использования. Модель — ваша собственность.

Математика Decimal

Полный отказ от галлюцинаций LLM при работе с финансовыми показателями.

ИИ только читает. Python считает.

Генеративные модели (LLM) используются исключительно для семантического анализа текстов, парсинга таблиц и поиска структурных аномалий.

Детерминированные вычисления

Все числовые показатели (сумма по разделам, НДС, БДДС, маржа) рассчитывает строгий детерминированный алгоритм на Python (с использованием библиотеки `decimal`).

- Сумма разделов сходится с итогом источника до рубля.
- Никаких округлений чисел с плавающей точкой (float).

ETL и Pydantic Валидация

Превращение строительного хаоса (PDF, Excel, сканы) в строгий JSON.

Машинное зрение (Computer Vision)

Агент-Администратор использует модели LayoutLM для извлечения таблиц из сложных документов, включая сканы с синими печатями, подписями и искажениями перспективы.

Pydantic Схемы

Все извлечённые нейросетью данные проходят жёсткую валидацию типов через библиотеку Pydantic. Если ИИ попытался вставить текст в поле суммы, весь JSON-блок отклоняется и отправляется на регенерацию.

Сайзинг Инфраструктуры

Для обеспечения производительности (SLA проверки сметы < 1 часа) требуются мощные GPU.

КОМПОНЕНТ	МИН. ТРЕБОВАНИЯ
VRAM (GPU)	2× 24GB (A30/A10G)
ОЗУ (RAM)	256 GB
Storage	2 TB NVMe SSD

* Оптимальная конфигурация: 4x NVIDIA A100 (80GB).



Оркестрация Агентов (RabbitMQ)

Как 9 агентов работают параллельно, не блокируя друг друга.

Message Broker

Используем RabbitMQ для асинхронного обмена сообщениями между микросервисами (агентами).

Параллелизм

Агент-Юрист и Агент-Сметчик работают над одним документом одновременно. Оркестратор собирает их ответы.

Масштабирование

Горизонтальное масштабирование через Kubernetes. Больше документов = больше workers.

Границы проекта (Scope)


Мы запускаемся за 135 дней, потому что не пишем костыли к вашему монолиту 1С.

StorHaus и API

Наполнение данными решается посредством интеграции со StorHaus (нашим Data Warehouse) или через классические REST API.

Ограничение: 1С:ERP

Глубокая двусторонняя интеграция (написание кастомных коннекторов, обратная запись в регистры бухгалтерии) **не входит в базовый этап запуска**. Это минимизирует риски поломки ваших текущих бизнес-процессов.



БАЗА ДАННЫХ

Vector DB & RAG

- Исторические сметы хранятся в векторной базе (Qdrant).
- Семантический поиск по 250+ объектам для поиска аналогов в миллисекундах.

Дорожная карта (135 дней)

Месяц 1: Infra

Сайзинг GPU, развёртывание LLM.

Месяц 2: Data

Загрузка исторических 250+ объектов.

Месяц 3-4: Агенты

Калибровка и сдача в ОПЭ.

Целевой SLA качества ИИ-вывода:

80%+

Точность по контрольному чек-листу для перехода в промышленную эксплуатацию.

LLM-Вендорлок

Открытые веса

Мы не привязаны к Llama или Qwen. Модели меняются изменением YAML-конфига. Мы гарантируем работу системы даже при санкциях.

Observability

- **Prometheus:** Сбор метрик ответов (время генерации).
- **Grafana:** Дашборды загрузки VRAM.
- **ELK:** Логирование каждого действия агента для ИБ.

CI/CD

Обновление весов модели происходит бесшовно (Blue/Green Deployment) без даунтайма.

Безопасность: Ролевая Модель

RBAC & SSO

Полная интеграция с корпоративным Active Directory / LDAP. Инженер ПТО не увидит дашборд с EBITDA.

Поддержка и Гарантии

12 Месяцев

Гарантия на код и устранение дефектов.

24 Часа

Критический SLA реакции.

Обучение RAG

Доп. опция по расширению опорной базы.

Стек Технологий


Backend

Python 3.11+, FastAPI, Pydantic, SQLAlchemy, Celery.

AI / ML

vLLM, HuggingFace Transformers, LangChain, Qdrant.

PORTFOLIO PERFORMANCE OVERVIEW



Внешние API
(Снабжение)

Интеграция с Контур.Фокус и Спарк для Агента-Снабженца происходит через изолированный шлюз.

Скорость процессинга 500 стр. PDF:

1 час

Параллельный парсинг и валидация 9 агентами.

Отказоустойчивость

Резервное копирование

Настраивается силами IT заказчика. Мы предоставляем скрипты дампа базы PostgreSQL.

Разделение труда (Агенты)

Agent 1-3

Парсинг, OCR, нормализация
(Администратор).

Agent 4-7

Смысловая экспертиза (ГИП,
Сметчик, Юрист).

Agent 8-9

Сводная экономика и График
(Экономист, РП).

Права на код

Интеллектуальная собственность

Базовое ядро (FastAPI/Промпты) принадлежит 7КЛ.
Данные, отчёты и обученные вектора (RAG) принадлежат
Заказчику.

Масштабируемость

→ Добавление новых типов документов (КС-3, М-29) происходит через донастройку промптов, а не переписывание ядра.

Docker

Система поставляется в виде набора Docker-контейнеров.

Модуль расчёта (Детали)

Сложные формулы

ИИ не считает НДС, индексы-дефляторы или транспортные наценки. Это делает Python, опираясь на извлеченные ИИ базовые ставки.

Внедрение начинается с:

Аудита ИТ

Выезд нашего архитектора в ваш дата-центр.

Итог Технической Архитектуры

Zero
Trust