

Инженерная Безупречность

Zero Trust изоляция, детерминированная математика Decimal и локальные открытые веса (LLM).



Принцип Zero Trust

Абсолютная изоляция вашей коммерческой тайны. Физическое отсутствие связи с публичными облаками.

Изоляция данных

Система разворачивается на выделенных серверах (Bare Metal или изолированных VM) внутри контура Заказчика.

- Сметы, финмодели, историческая БД обрабатываются исключительно локальными моделями.
- Никаких API вызовов к OpenAI, Yandex или Sber.

Два Контура

Внутренний контур (Закрытый) используется для смет и договоров. Внешний контур (Анонимный) применяется для поиска подрядчиков. Передача данных во внешний контур выполняется после алгоритмического удаления ИНН, адресов и сумм.

Стоимость генерации токенов в контуре (Zero Token Cost):

\$0.00

Плата за обращения к локальной LLM-модели не взимается и не зависит от интенсивности использования. Модель — ваша собственность.

Математика Decimal

Полный отказ от галлюцинаций LLM при работе с финансовыми показателями.

ИИ только читает. Python считает.

Генеративные модели (LLM) используются исключительно для семантического анализа текстов, парсинга таблиц и поиска структурных аномалий.

Детерминированные вычисления

Все числовые показатели (сумма по разделам, НДС, БДДС, маржа) рассчитывает строгий детерминированный алгоритм на Python (с использованием библиотеки `decimal`).

- Сумма разделов сходится с итогом источника до рубля.
- Никаких округлений чисел с плавающей точкой (float).

ETL и Pydantic Валидация

Превращение строительного хаоса (PDF, Excel, сканы) в строгий JSON.

Машинное зрение (Computer Vision)

Агент-Администратор использует модели LayoutLM для извлечения таблиц из сложных документов, включая сканы с синими печатями, подписями и искажениями перспективы.

Pydantic Схемы

Все извлечённые нейросетью данные проходят жёсткую валидацию типов через библиотеку Pydantic. Если ИИ попытался вставить текст в поле суммы, весь JSON-блок отклоняется и отправляется на регенерацию.

Сайзинг Инфраструктуры

Для обеспечения производительности (SLA проверки сметы < 1 часа) требуются мощные GPU.

КОМПОНЕНТ	МИН. ТРЕБОВАНИЯ
VRAM (GPU)	2× 24GB (A30/A10G)
ОЗУ (RAM)	256 GB
Storage	2 TB NVMe SSD

* Оптимальная конфигурация: 4x NVIDIA A100 (80GB).



Оркестрация Агентов (RabbitMQ)

Как 9 агентов работают параллельно, не блокируя друг друга.

Message Broker

Используем RabbitMQ для асинхронного обмена сообщениями между микросервисами (агентами).

Параллелизм

Агент-Юрист и Агент-Сметчик работают над одним документом одновременно. Оркестратор собирает их ответы.

Масштабирование

Горизонтальное масштабирование через Kubernetes. Больше документов = больше workers.

Границы проекта (Scope)

Мы запускаемся за 135 дней, потому что не пишем костыли к вашему монолиту 1С.

StorHaus и API

Наполнение данными решается посредством интеграции со StorHaus (нашим Data Warehouse) или через классические REST API.


Ограничение: 1С:ERP

Глубокая двусторонняя интеграция (написание кастомных коннекторов, обратная запись в регистры бухгалтерии) **не входит в базовый этап запуска**. Это минимизирует риски поломки ваших текущих бизнес-процессов.

Архитектура NLP (LayoutLM)

Почему мы не используем классические OCR (Tesseract или ABBYY)?

- **Проблема классики:** OCR просто переводит пиксели в текст, но не понимает, что число "100" в столбце "Объём" связано с названием "Бетон" на две строки выше.
- **Решение LayoutLM:** Трансформер анализирует не только текст, но и 2D-расположение блоков на листе. Он "видит" структуру документа так же, как человек.
- **Устойчивость:** Модель игнорирует синие печати, подписи ручкой и заломы отсканированной бумаги.



Жёсткая Валидация Pydantic

Защита от структурных галлюцинаций LLM.

Проблема генеративных моделей

Иногда LLM вместо числа `100.5` выдаёт строку `около ста`. Если это попадёт в математический модуль — система упадёт с `TypeError`.

Решение (Схемы)

Вывод LLM перехватывается Pydantic. Если поле ``volume`` (`float`) содержит текст, Pydantic выбрасывает `ValidationError`.

Оркестратор (LangChain) ловит ошибку, добавляет её в `prompt` и заставляет LLM регенерировать ответ. В базу попадает только 100% чистый JSON.

Векторное хранилище (RAG)

Как система понимает, что "Цемент М500" и "Портландцемент М500" — это одно и то же.

Эмбединги (Embeddings)

Каждая из 10 000 позиций исторической сметы переводится в числовой вектор из 768 измерений.

Qdrant Vector DB

При поступлении новой сметы система ищет ближайшие вектора в многомерном пространстве. Поиск занимает 20 миллисекунд.

Семантический мэтчинг

ИИ находит аналог не по точному совпадению букв, а по **смыслу**. Это решает проблему опечаток и сокращений.

Оркестрация очередей

Асинхронная архитектура позволяет выдерживать пиковые нагрузки в период закрытия актов КС-2 (конец месяца).

- **Message Broker:** RabbitMQ принимает задачи на анализ и складывает в очередь.
- **Workers:** 9 Агентов подписаны на разные топики. Агент-Юрист ждет договоры, Агент-ПТО ждет акты.
- **Resilience:** Если воркер падает (Out of Memory на GPU), задача не теряется, а возвращается в очередь для другого воркера (Celery).

Пайплайн развертывания (CI/CD)

Бесшовные обновления без даунтайма критической инфраструктуры.

Docker & Kubernetes

Весь программный комплекс поставляется в виде набора контейнеров (Microservices). Кластер K8s управляет их жизненным циклом и масштабированием.

Blue/Green Deployment

При выходе новой версии модели весов, мы поднимаем её параллельно старой (Green контур). Трафик плавно переводится на новую модель. Если метрики падают — автоматический Rollback за 1 секунду.

Отказоустойчивость & Бэкапы

Active-Passive Cluster

Для Enterprise-внедрений мы рекомендуем развертывание двух нод базы данных (PostgreSQL + Qdrant) в разных дата-центрах или стойках.

Точки восстановления (RPO / RTO)







- **RPO (Потеря данных):** < 5 минут (за счет репликации WAL-логов).
- **RTO (Время восстановления):** < 1 часа (автоматический failover).

ELK Stack & Grafana

Полный контроль над состоянием системы и логгирование каждого шага ИИ.

- **Grafana:** Дашборды мониторинга загрузки GPU (температура, VRAM), CPU и ОЗУ.
- **Prometheus:** Сбор метрик ответов (Latency LLM, длина очереди).
- **ELK (Elastic, Logstash, Kibana):** Централизованный сбор логов. CISO всегда знает, кто и какой PDF загрузил в систему.

PORTFOLIO PERFORMANCE OVERVIEW



СВЯЗЬ СО ВНЕШНИМИ СИСТЕМАМИ

Мы не монолит. Мы открытая экосистема.

REST API / GraphQL

Любая ERP-система (1C, SAP) может отправить нам PDF через POST-запрос и получить обратно размеченный JSON с выявленными ошибками.

StorHaus DWH

Нативная интеграция с корпоративным хранилищем данных для построения сквозной BI-аналитики (PowerBI / Superset).

Active Directory

SSO-авторизация (SAML 2.0 / OAuth).
Права доступа (RBAC) синхронизируются с вашей корпоративной сетью.


Независимость от моделей (Vendor Lock-in)

Свобода выбора

Мы не привязываем вас к одной модели (например, Llama 3). Архитектура позволяет менять "мозг" системы простым изменением YAML-конфига в LangChain.

Защита от санкций

Вышли новые мощные открытые веса (Mistral, Qwen)? Мы просто скачиваем их и разворачиваем в вашем контуре. Вы всегда на острие технологий без риска отключения API.



CORE

Почему Float — это зло?

Для финансовых расчетов мы используем исключительно `decimal` модуль Python.

- **Проблема Float:** Компьютер не может точно представить дробные числа. ``0.1 + 0.2`` во Float равно ``0.30000000000000004``.
- **Накопительная ошибка:** На смете в 15 000 строк эта погрешность выливается в расхождение итоговой суммы на десятки рублей. Бухгалтерия Заказчика завернет такой акт.
- **Решение Decimal:** Гарантирует абсолютную математическую точность до последней копейки.

Защита от внутренних угроз

Аудитный след (Audit Trail)

Каждое изменение в смете (кто подтвердил аномалию, кто проигнорировал её) записывается в неизменяемый лог. Сговор инженера технадзора с подрядчиком становится математически невозможным.

Время парсинга и валидации 500 стр. PDF:

~45 МИН

На кластере из 4x NVIDIA A100. Это в 150 раз быстрее человеческого отдела ПТО.

Логический слой

Agent 1-3 (Data)

Распознавание, очистка, ETL,
приведение к единой
номенклатуре.

Agent 4-7 (Logic)

Смысловые проверки (Двойной
учет, подмена материалов).

Agent 8-9 (Finance)

Сводная математика, БДДС,
график кредитования.

Масштабируемость платформы

Архитектура спроектирована так, чтобы добавлять новые функции без изменения ядра.

- **Год 2:** Интеграция с BIM-моделями (IFC парсинг) для сверки объемов напрямую с 3D-чертежами.
- **Год 3:** Предиктивная аналитика срывов сроков на базе IoT датчиков со стройплощадки.



Матрица ответственности (SLA)

L3 Support

Мы гарантируем исправление критических багов (система упала, парсинг не работает) в течение 24 часов.

Обучение модели

Корректировка промптов и дообучение RAG-базы под новые нестандартные формы смет подрядчиков — плановое релизное окно 1 раз в квартал.

Технический аудит ЦОД

Для старта проекта нашему архитектору необходимо 1 час общения с вашим IT-директором для заполнения опросного листа:

- Сетевая топология (VLAN, Firewall).
- Выделение виртуальных машин / Bare Metal.
- Доступность GPU.

Технологическое Лидерство

Zero Trust

+7 (495) 198-14-77